Relatório 6 - Embedding

Natalie Tolentino Serafim

Descrição da atividade

No módulo 6 a ferramenta Qdrante foi apresentada para prática de embeddings. Qdrant é um banco de dados vetorial que permite realizar buscas semânticas de forma ágil. No Qdrant Cloud há modelos de inferência que podem ser incorporados ao modelo, sendo utilizado nessa atividade o *sentence-transformers/all-MiniLM-L6-v2* que é gratuito.

O guia direciona para um registr5o na conta Cloud do Qdrant afim de criar um *cluster* gratuito e as credenciais necessárias. Utilizando SDKs oficiais é possível iniciar o uso da ferramenta localmente, apenas instalando a biblioteca segundo a linguagem desejada.

Como prática foi gerado um código para criar um cliente que se conecta ao Qdrant Cloud e realiza inserções e buscas nas *collections*.

Na documentação oficial que incentiva o uso do Qdrant Cloud os embeddings não são gerados localmente, mas um objeto Documento é enviado com o texto e nome do modelo, sendo incorporados pelo Qdrant Cloud Inference.

Com o conteúdo armazenado é possível realizar a busca semântica, afim de dada uma query os resultados são retornados pela semelhança entre si, não necessariamente fazendo match textual.

```
64                "description": menu_item[1],
65                "year": menu_item[2],
66                "category": menu_item[3],
67            }
68        )
69        points.append(point)
70
71    # upsert points to collection
72    client.upsert(
73      collection_name="movie",
74      points=points,
75    )
76
77    # generate query embedding
78    query_text = "animais marinhos em busca de aventura"
79
80    # search for similar menu items
81    results = client.query_points(
82        collection_name="movie",
83        query=Document(text=query_text, model="sentence-transformers/all-MiniLM-L6-v2"),
84        with_payload=True
```

PROBLEMS 147 OUTPUT TERMINAL DEBUG CONSOLE PORTS SPELL CHECKER 143

TERMINAL

```
(.venv) PS C:\Users\natal\Fastcamp-de-Agentes-Inteligentes\Aula 6> py .\qdrant_pratica.py
Item: Procurando Nemo
Score: 0.5911205
Description: Um peixe-palhaço atravessa o oceano em busca de seu filho desaparecido...
Year: 2003
---
Item: O Senhor dos Anéis: A Sociedade do Anel
Score: 0.5576142
Description: Um jovem hobbit embarca em uma jornada para destruir um anel poderoso...
Year: 2001
---
```

Figura 1 Parte do código e resposta retornada durante prática

Já o segundo guia apresenta uma aplicação também utilizando o Qdrant mas agora executando em um serviço de nuvem chamado Elestio. Afim de evitar custos e aplicar outros conceitos estudados adaptei o guia para fazer as execução por Docker localmente.

A aplicação consiste em em um fluxo N8N em que um agente de IA ao receber uma mensagem por chat engloba um modelo que compreende a mensagem, armazena o histórico e responde com a busca no banco de dados vetorial.
Para que este processo ocorra é necessário que outro fluxo seja gerado, sendo este responsável por realizar iterações em links indicados afim de coletar o texto das páginas e armazenar vetorialmente.

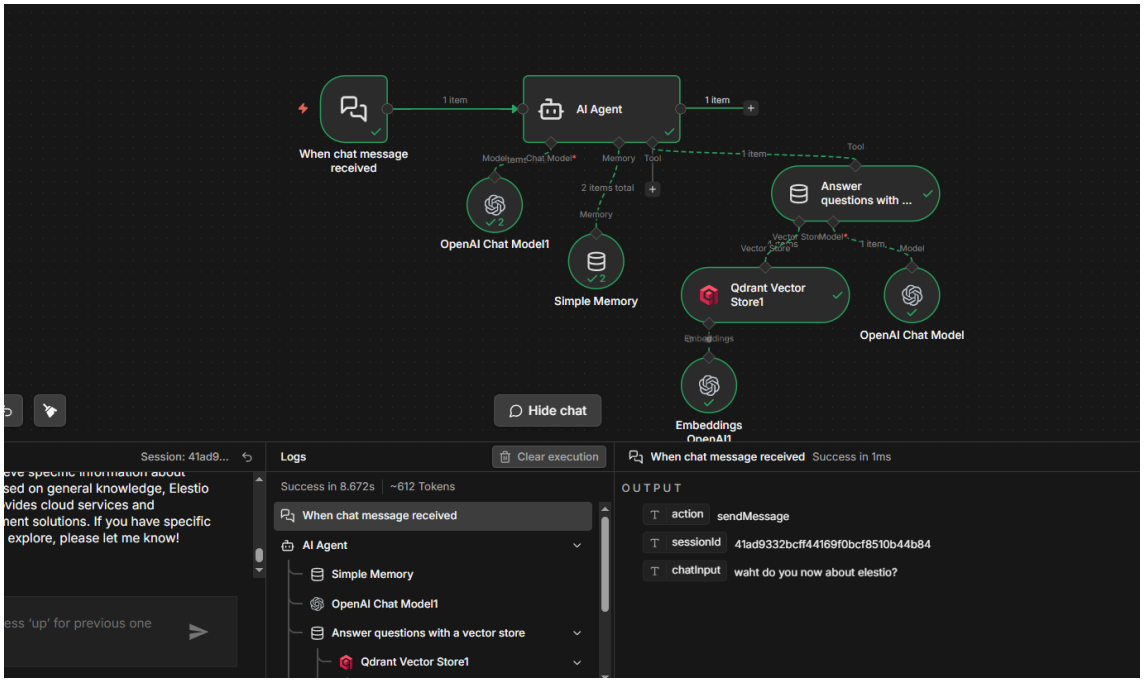

Figura 2 Fluxo agêntico realizando busca dada a mensagens recebidas

Dado as possibilidades de configuração no N8N realizei alguns testes afim de diminuir o overlap e testar o impacto.

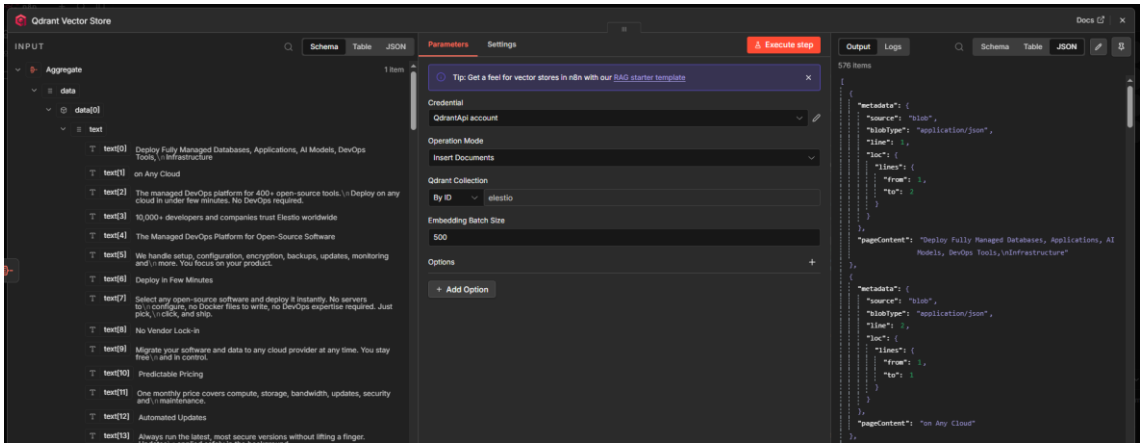

Figura 3 Transformação de dados recuperados do link em json padronizado.

Algo que achei fantástico na ferramenta do Qdrant é o seu painel de visualização. Ao olhar uma collection pelo painel podemos visualizar de forma bem estruturada os documentos armazenados, e até mesmo gráficos de dispersão de como cada ponto foi classificado.

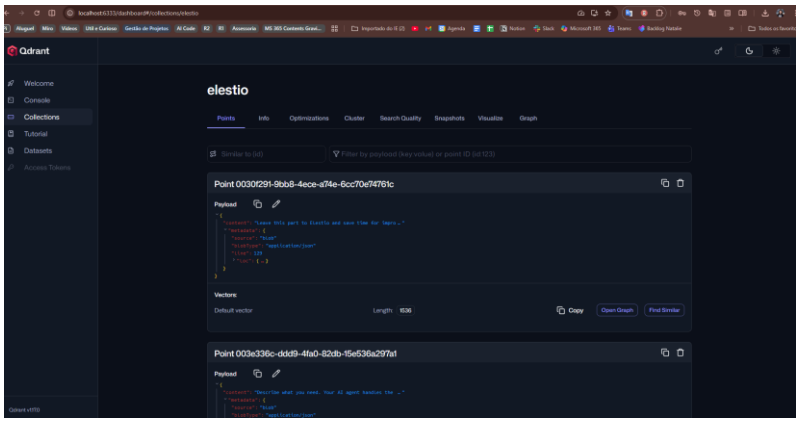

Figura 4 Página inicial de uma collection

Figura 5 Representação gráfica dos pontos no espaço vetorial referentes a inferência com links da web

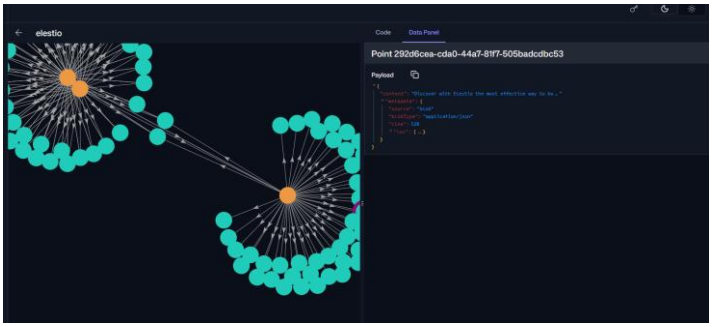

Figura 6 Grafo de conexões entre os pontos

Figura 7 Testes alterando parâmetros como overlap e visualizando o distanciamento vetorial causado pela menor semelhança entre os blocos de texto

Dificuldades

No segundo guia optei por não seguir com a ferramenta de nuvem Elestio e rodar a aplicação em um container Docker local. Com isso enfrentei alguns erros nas primeiras tentativas mas que compreendendo melhor sobre o Qdrant consegui corrigir e disponibilizar a imagem Docker rodando localmente.

Conclusões

Embora já tenha experimentado outras ferramentas para bancos vetoriais como o ChromaDB, a experiência com o Qdrant foi muito satisfatória. A estrutura em código para criar uma collection, adicionar itens, indicar modelos de inferência dos embeddings e realizar buscas é simples e facilmente compreendida. Mas o que mais me chamou atenção foi seu painel para visualizar o banco vetorial graficamente, algo que tangibilizou melhor compreensão dos cálculos realizados para buscas semânticas.

Referencias

https://qdrant.tech/documentation/cloud-quickstart/

https://www.youtube.com/watch?v=cCDAY0nb0T0